

Assignment 4

107062208 邱靖豪

(a) How to use the function “`scipy.sparse.linalg.eigs`.” ?

這個 function 的功能主要是用來算放進去的矩陣的 eigenvectors 跟對應的 eigenvalues，以我的 code 當範例，`spla` 是先從 `scipy.sparse.linalg` 引入的，接著，就使用 `eigs` 的功能，`L` 在這裡是那個稀疏矩陣，`k = m`，`k` 是希望得到的 eigenvectors 數，而 `which = 'SR'` 指的是找到前 `k` 小，同時也是實數的 eigenvectors。而等號左邊的 `vals, vecs`，指的是得到的 eigenvalues 跟 eigenvectors。

```
import scipy.sparse.linalg as spla
vals, vecs = spla.eigs(L, k=m, which='SR')
```

(b) How K-means algorithm works?

K-means algorithm 是一種演算法，目標是將 `n` 個待觀察物分類成 `k` 個群集，K-Means 是聚類演算法中的最常用的一種，演算法最大的特點是簡單，好理解，運算速度快。他分成三個步驟，首先，(1) Initialisation，先隨機舉出 `k` 個初始群集中心 (means 或 centroids)。接著是 (2) Assignment，以「連結各個觀察物最近的 centroids」，創造出 `k` 個 clusters，方法是計算每筆資料到 `k` 個群心的歐式距離(歐基李德距離 Euclidean distance)。再來是 (3) Update，將每筆資料分類給距離最近的那

個群心，接著，每個群心內都會有被分類過來的資料，用原本的資料加上被分類過來的資料，更新一次新的群心。反覆以上步驟，直到群心沒有太大變動，演算即結束。


(c) Original images and the figures after running two segmentation methods.

Original image:


Original:



RGB K-Means:



Spectral Clustering:




My image1:


Original:



RGB K-Means:




Spectral Clustering:




My image2:


Original:



RGB K-Means:



Spectral Clustering:



(d) Discussion about what kinds of images prefer which segmentation methods

從我自己挑的兩張圖看來，只要是圖形顏色單調，或者是形狀沒那麼複雜


的，**RGB K-Means** 的效果較好，反之，比較複雜的圖案，跟顏色比較有陰

影對比的圖片，用 **Spectral Clustering** 會比較好。

(e) Figures of segmentation results for different number of eigenvectors and clusters

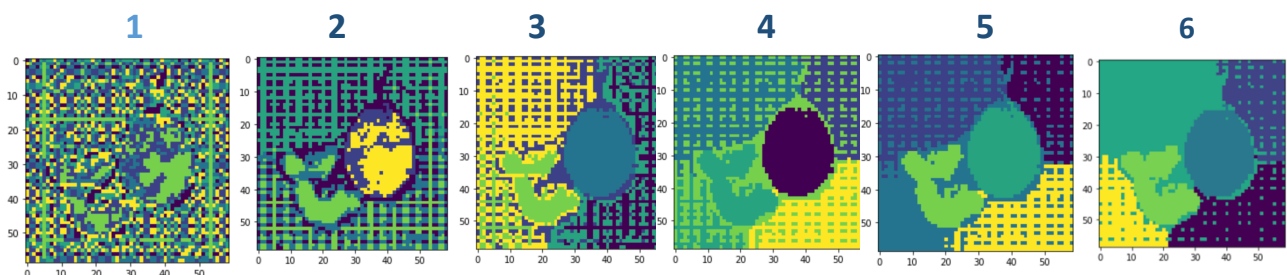
Different numbers of eigenvectors

Cluster = 4



Different numbers of eigenvectors


Cluster = 6



(f) Discussion about the influence of different number of eigenvectors and clusters

Clusters 在上面提過，在這個演算法裡的功能是代表分出類群，因此， $cluster=n$ 代表把圖片分成 n 個色塊，由上題的 figures 可以發現，同一張圖片當 clusters 的數值較大時，需要較多的 eigenvectors 才能清楚的顯示圖片，以 eigenvectors=4 作為對照， $cluster=4$ 時能比較好看出輪廓了。但假如 cluster 數過小，分成的色塊也就比較少，假使 eigenvectors 數多，還是沒辦法讓輪廓較清楚。以 $cluster=2$ 為例，甚至當 eigenvector 變大時，沒辦法將完整的輪廓顯示出。

Different numbers of eigenvectors



(g) Discussion about the COO format

它是一種儲存 sparse matrix 的方式，因為在 sparse matrix 中 value 為 0 的數值很多，用一般的二維矩陣來記錄很佔空間，因為只會紀錄很分散的非零值，所以，COO format 就是用來優化此問題的方法。考慮原本的 A 是

N element 大小的 sparse matrix，但經過 COO format 後，matrix 的大小就會變為 sparse matrix 中不為 0 的 element 個數(k)*3(row index、column index、value)，分別用來記錄那些非零元素得 row 值、column 值以及數值大小，這樣子存取空間是 3k，考慮到 $k \ll N$ ，所以 $3k \ll N$ ，存取空間來說，應該是縮小不少。但是，COO 不支援儲存和刪減 element，除非轉換為其它格式的矩陣，否則很難對其做操作或是矩陣運算，因此在計算 eigenvalues 上，所需的時間比較長，因為還要轉換成可運算的矩陣，這是 coo format 較不方便的地方。

(h) Result and discussion on the bonus question

Affinity measure	Expression
Random	$W_r = X_r X_r^T$, where X_r is a $n \times d$ random matrix
Trivial	$W_t = X X^T$
Exponential	$w_{ij} = e^{-d^2(x_i, x_j)}$ con $w_{ii} = cte$
Scaled exponential	$w_{ij} = e^{-d^2(x_i, x_j)/(\sigma_i \sigma_j)}$, with $w_{ii} = 0$, where $\sigma_i = d(x_i, x_N)$ and x_N is the N -th nearest neighbor

Fig 2. Weighted graph with three nodes

這是在網路上搜尋到的論文，所做的比較。根據它的公式去解讀的話，我們使用 scaled exponential affinity 的話，切割出來的照片會比較少鋸齒，物件跟背景的切割會比較圓滑。我們能了解到，pixel 之間的 weight 如果是用作業中的公式，就會發現到如果兩個顏色差異是一樣的，他們的 weight 就

會是一樣的，比如說一組是紅 (1,0,0) 黑 (0,0,0)，另一組是藍 (0,1,0) 跟黑，量來說差異是一樣的，然而卻有不同的顏色。因此，如果使用 scaled exponential affinity，每個 weight 在運算時，他的 pixel 都有不同的 σ 值，所以即使他們在顏色編碼上的差異一樣，他們的 weight 會不一樣，這樣就能分辨出顏色差距一樣，但實際顏色不一樣的組合，另外，這篇論文的算法是用距離，但是，我覺得因為 pixel 利用到的編碼概念，跟算距離的概念是可以相通的，所以這個方法在此也適用。

以下是 example·(a)為原圖·(b)是 trivial affinity·(c)是 exponential affinity (d)是 scaled exponential affinity，可以看出 scaled exponential affinity 的確比較光滑，符合原圖輪廓一些。

參考資料及例子來源：

<http://diegopeluffo.com/publicaciones/STSIVA2010.pdf>

